

Aliya Harta Ary Utama
18223081
II4013 Data Analytics - Tugas 3

1. Identifikasi Jenis Data

a. Dataset A

Penjelasan : Dataset A terdiri dari Temperatur dan Jumlah Produk Cacat.

Jenis Data : *Low dimensional data*. Dataset ini hanya terdiri dari 2 variabel yaitu Suhu (*Temperature*) dan Jumlah Cacat (*Defective Products*). Dimana data ini memetakan hubungan suhu dan jumlah produk cacat saja. Serta, sesuai dengan pengertian dari *Low dimensional data*, yaitu ketika jumlah fitur kurang dari 3.

Teknik Visualisasi : *Scatter Plot*

Alasan Pemilihan Teknik : *Scatter Plot* adalah sebuah teknik memetakan 1 fitur terhadap 1 fitur lainnya, dimana teknik ini sangat efektif untuk memvisualisasikan data dua variabel dan untuk melihat apakah terdapat hubungan, korelasi, atau pola antara dua variabel tersebut secara langsung.

b. Dataset B

Penjelasan : Dataset B terdiri dari 5 fitur, yaitu *Vibration*, *Temperature*, *Current*, *Pressure*, dan *Noise*.

Jenis Data : *High dimensional data*. Karena dataset ini memiliki 5 fitur variabel numerik untuk setiap mesin (*Vibration*, *Temperature*, *Current*, *Pressure*, dan *Noise*). Sesuai dengan definisi *High dimensional data*, apabila sebuah dataset memiliki lebih dari 3 fitur, maka dapat digolongkan ke *High dimensional data*

Teknik Visualisasi : *Dimensionality Reduction* seperti PCA (Principal Component Analysis), MDS (Multidimensional Scaling), atau Sammon Mapping.

Alasan Pemilihan Teknik : Keterbatasan kemampuan manusia dalam memvisualisasikan dataset pada lebih dari 3 dimensi ruang, sehingga dibutuhkan *dimensionality reduction*. PCA/MDS memungkinkan untuk

mereduksi 5 dimensi sensor tersebut menjadi 2 dimensi utama tanpa banyak kehilangan informasi data aslinya, sehingga bisa diplot pada scatter plot 2D biasa.

c. Dataset C

Penjelasan : Dataset C terdiri dari Jumlah Produksi dalam keberjalanan jam.

Jenis Data : *Time series data*. Jumlah produksi dicatat secara berurutan berdasarkan interval waktu yang tetap yaitu pada setiap jam.

Teknik Visualisasi : *Line chart* (Visualisasi Sederhana), *Spectral analysis* (Analisis Mendalam).


Alasan Pemilihan Teknik : *Line chart* menghubungkan titik-titik data secara berurutan berdasarkan waktu dari kiri ke kanan, sehingga sangat memudahkan untuk melihat tren naik-turun dan pola periodik/berulang seiring berjalannya waktu.

2. Visualisasi

a. Visualisasi *Scatter Plot* Dataset A

```
# Dataset A: Scatter Plot Suhu vs Cacat
plt.figure(figsize=(12, 5))
plt.subplot(1, 2, 1)
plt.scatter(df_A['Temperature_C'], df_A['Defective_Products'], color='red')
plt.title('Dataset A: Suhu vs Cacat Produk')
plt.xlabel('Suhu Mesin (°C)')
plt.ylabel('Jumlah Cacat Produk')
plt.grid(True)
plt.tight_layout()
plt.show()
```

Tabel 1 Code Visualisasi Scatter Plot Dataset A



Tabel 2 Hasil Visualisasi Scatter Plot Dataset A


Pola Hubungan pada Dataset A : Jika kita lihat dari visualisasi terhadap dataset A diatas, dapat terlihat bahwa terdapat **korelasi positif yang kuat / linear** antara Suhu Mesin dan Jumlah Cacat Produk. Dimana, seiring dengan kenaikan suhu mesin, jumlah produk cacat juga ikut bertambah. Dapat terlihat pada suhu 58°C, jumlah produk cacat ada 3, selanjutnya semakin tinggi suhu, semakin banyak pula jumlah produk cacat, hingga kita lihat pada suhu 73°C, jumlah produk cacat mencapai 11.

b. Visualisasi *Line Chart* Dataset B

```
# Dataset C: Line Chart Produksi per Jam
plt.figure(figsize=(12, 5))
plt.subplot(1, 2, 2)
plt.plot(df_C['Hour'], df_C['Production'], marker='o', linestyle='-',
color='blue')
plt.title('Dataset C: Jumlah Produksi per Jam')
```

```
plt.xlabel('Jam ke-')
plt.ylabel('Jumlah Produksi')
plt.grid(True)
plt.tight_layout()
plt.show()
```

Tabel 3 Code Visualisasi Line Chart Dataset C



Tabel 4 Hasil Visualisasi Line Chart Dataset C

Pola Periodik pada Dataset C : Berdasarkan hasil visualisasi line chart dataset C diatas, terdapat pola periodik yang berulang secara teratur setiap 4 jam. Produksi dimulai dari 50 unit, naik mencapai puncak 58 unit di jam berikutnya, kembali ke 50, turun ke titik terendah 42 unit, dan kemudian kembali ke titik awal 50 unit. Dimana terdapat siklus 50 -> 58 -> 50 -> 42, dan siklus ini ini terus berulang secara konstan.

3. Analisis Data Berdimensi Tinggi

Dalam analisis data berdimensi tinggi, saya menggunakan **Python**.

a. Menggunakan PCA untuk mereduksi dimensi

```
# Memilih fitur numerik untuk PCA
features = ['Vibration', 'Temperature', 'Current', 'Pressure', 'Noise']
x = df_B[features].values

# Standarisasi data
x = StandardScaler().fit_transform(x)

# Mengaplikasikan PCA untuk reduksi ke 2 dimensi
pca = PCA(n_components=2)
principalComponents = pca.fit_transform(x)
df_pca = pd.DataFrame(data=principalComponents, columns=['PC1', 'PC2'])
df_pca['Machine'] = df_B['Machine']

# Visualisasi Hasil Proyeksi PCA ke 2D
plt.figure(figsize=(8, 6))
plt.scatter(df_pca['PC1'], df_pca['PC2'], color='green', s=100)


# Menambahkan label nama mesin pada tiap titik
for i, txt in enumerate(df_pca['Machine']):
    plt.annotate(txt, (df_pca['PC1'][i], df_pca['PC2'][i]),
                 textcoords="offset points", xytext=(0,10), ha='center')

plt.title('Dataset B: Proyeksi PCA 2D untuk Mesin')
plt.xlabel('Principal Component 1')
plt.ylabel('Principal Component 2')
plt.axhline(0, color='black', linewidth=0.5)
plt.axvline(0, color='black', linewidth=0.5)
plt.grid(True)
```

```
plt.show()
```

Tabel 5 Code Visualisasi PCA Dataset B

b. Scatter Plot 2D



Tabel 6 Hasil Visualisasi PCA Dataset B

Interpretasi : Berdasarkan visualisasi scatter plot PCA 2D tersebut, terlihat jelas adanya progresi kondisi operasional yang berurutan dari Mesin 1 (M1) hingga Mesin 8 (M8) di sepanjang sumbu Principal Component 1 (PC1), di mana titik-titik mesin membentuk lintasan kurva yang mulus tanpa adanya anomali atau *outlier*.

Pola ini mengindikasikan bahwa peningkatan nilai pada kelima sensor terjadi secara bertahap dan konsisten di seluruh mesin, sehingga pihak pabrik dapat dengan mudah menyimpulkan bahwa semua mesin beroperasi pada spektrum kondisi yang seragam, mulai dari M1 dengan beban operasional paling rendah hingga M8 dengan beban paling tinggi.

c. Alasan menggunakan teknik

Dataset B sangat sulit divisualisasikan secara langsung dengan scatter plot biasa karena memiliki 5 fitur. Jika kita membuat scatter plot biasa, kita hanya bisa melihat 2 variabel pada satu waktu, sehingga gambaran keseluruhan mesin tidak terlihat utuh.

Teknik PCA dipilih karena sangat sesuai, dimana secara matematis mengekstraksi kombinasi linear dari kelima fitur tersebut dan mengubahnya menjadi komponen-komponen utama. Kita memproyeksikan data 5D tersebut menjadi 2 dimensi saja yaitu PC1 dan PC2 yang merepresentasikan variansi terbesar dalam data. Hasilnya adalah peta kedekatan karakteristik antar mesin dalam satu scatter plot 2D yang sederhana dan informatif.

Lampiran

<https://colab.research.google.com/drive/1koUIjVHxXrXPDryKxcuLS15NmFRUTzR?usp=sharing>